

Mini-Tutorial: Ein eigenes Korpus erstellen und annotieren

Per Hand oder mit einfachen Tools

Stefan Hartmann

2026-06-14

Table of contents

1 Einleitung

In der Korpuslinguistik gibt es eine ganze Reihe von Ressourcen, mit denen wir arbeiten können, wenn wir Fragestellungen korpuslinguistisch angehen wollen. So gibt es für viele gut untersuchte Sprachen Referenzkorpora, und es gibt auch einige frei verfügbare Spezialkorpora zum Sprachgebrauch in bestimmten Kontexten. In vielen Fällen müssen wir aber doch eigene Datensätze zusammenstellen, um unsere Forschungsfragen zu beantworten. Deshalb zeigt dieses Tutorial, wie man möglichst effizient und doch systematisch ein eigenes Korpus zusammenstellen und für die weitere Analyse aufbereiten kann. Dabei orientieren wir uns an einem konkreten Beispiel, um nicht nur die handwerklichen Aspekte zu beleuchten, sondern auch aufzuzeigen, wofür die hier vorgestellten Methoden denn letztlich angewendet werden.

Ich werde im folgenden zwei Wege aufzeigen. Der erste – “Quick & dirty” – funktioniert ohne größere Hilfsmittel; man braucht lediglich einen Texteditor wie [Notepad++](#) für Windows oder [BBEdit](#) für Mac (Ersteres ist kostenlos und open source; bei Letzterem genügt die – etwas versteckte – kostenlose Variante völlig). Der zweite – “Advanced” – greift auf fortgeschrittenere Tools zurück, insbesondere auf [Trafilatura](#). Im entsprechenden Abschnitt werden die technischen Voraussetzungen kurz erklärt.

2 Rechtliche und ethische Vorüberlegungen

Wir nutzen im Folgenden die Seite netzpolitik.org als Beispiel, anhand dessen wir ein kleines, selbst erstelltes Korpus erstellen. Der Vorteil dieser Seite ist, dass die Inhalte aller Artikel, soweit beim einzelnen Artikel nicht anders angegeben, unter der Lizenz [CC-BY-NC-SA 4.0](https://creativecommons.org/licenses/by-nc-sa/4.0/) verfügbar sind, die eine Nachnutzung zu nichtkommerziellen Zwecken erlaubt, solange die Nachnutzung unter Anwendung derselben oder einer vergleichbaren Lizenz erfolgt. Daher kann ich die Daten, die ich im Folgenden erstelle, im Begleitmaterial zu diesem Tutorial weitergeben, ohne die Urheber:innen um Erlaubnis fragen zu müssen.

Für viele Fragestellungen kann es auch notwendig sein, mit Daten zu arbeiten, bei denen das nicht möglich ist. Sofern die Urheber keine Lizenz angegeben haben, sind Texte (und natürlich auch Bildmaterialien etc., da sind die Regelungen teilweise sogar noch strenger) immer urheberrechtlich geschützt. Allerdings erlaubt das deutsche Urheberrecht sog. Data Mining zu wissenschaftlichen Zwecken, solange die Daten nicht weitergegeben und nach Abschluss der Forschungsarbeit gelöscht werden. (Disclaimer: Das ist eine grobe Wiedergabe meines eigenen, nicht-fachkundigen Verständnisses der aktuellen Rechtslage.)

Neben rechtlichen sollten auch ethische Erwägungen berücksichtigt werden, wenn man sich dafür entscheidet, ein Korpus aus öffentlich verfügbaren Webdaten zusammenzustellen. So sollte man von Massenabfragen absehen, die die Server einer Seite belasten. Darüber hinaus gilt es in einigen Fällen bspw. persönlichkeitsethische Fragen zu berücksichtigen - hier geben beispielsweise Luth, Marx, and Pentzold (2022) wertvolle Hinweise.

Wenn Sie bei der Datenerhebung möglicherweise mit sensiblen Daten zu tun haben, kann es u.U. sinnvoll sein, ein Ethikvotum bei einer Ethikkommission (z.B. Ihrer Fakultät, falls es dort eine gibt) einzuholen.

3 Technische Voraussetzungen

Wenn Sie die Techniken aus dem Advanced-Teil des Tutorials nutzen möchten, müssen Sie insbesondere die Software Trafilatura installieren, die ihrerseits eine Installation von Python (und ggf. noch anderer Abhängigkeiten) voraussetzt. Die [Dokumentation von Trafilatura](#) ist relativ einsteigerfreundlich gehalten. Wir werden außerdem mit dem NLP-Paket [spacy](#) arbeiten, das sich entweder über Python nutzen lässt oder auch in R über [spacyr](#). Hier erkläre ich aber entsprechender Stelle, wie die Installation vonstatten geht.

4 Konzeptionelle Überlegungen

Bevor wir ein Korpus zusammenstellen, müssen wir eine Vorstellung davon haben, was das Korpus beinhalten soll. Die Zusammenstellung des Korpus ergibt sich aus den Erfordernissen der jeweiligen Forschungsfrage – in Kombination mit möglichen Beschränkungen, die sich aus der Datenverfügbarkeit ergeben. So ist aus offensichtlichen Gründen ein Korpus zum Sprachgebrauch auf Wikipedia einfacher zusammenzustellen als ein hypothetisches Korpus zum Sprachgebrauch verdeckter Ermittler:innen in Usbekistan.

Im Folgenden wollen wir beispielhaft ein Korpus zusammenstellen, mit dem wir die Verwendung konzeptueller Metaphern im netzpolitischen Diskurs um die sog. Chatkontrolle. Dafür stützen wir uns auf Daten aus dem bereits erwähnten Portal netzpolitik.org. (Dass das Portal zur Chatkontrolle eine relativ klare, nämlich ablehnende, Position hat, stellt dabei für unsere Fragestellung, die ja auf die Untersuchung konzeptueller Metaphern abzielt, kein Problem dar, sondern kann durchaus auch ein Vorteil sein, da wir so auch die Frage stellen können, wie Metaphern zum “Framing” entsprechender politischer Pläne genutzt werden können. Gleichwohl wäre es für eine tatsächliche Analyse natürlich sinnvoll, sich bei der Erstellung eines Korpus auf mehr als nur ein Portal zu stützen.)

Die Datenmenge, die wir benötigen, hängt ebenfalls davon ab, was unsere Forschungsfrage ist und wie wir sie methodisch angehen wollen. Für eher quantitativ orientierte Herangehensweisen brauchen wir naturgemäß größere Datenmengen, für qualitative Arbeit genügt es oft, einige wenige Texte (diese aber vollständig und gründlich) einzubeziehen.

Auch wenn oft danach gefragt wird, ist es unmöglich, genaue Zahlen für die angemessene Größe eines Korpus zu nennen. Letztlich ist die Frage nach der Korpusgröße gerade für Seminar- und Abschlussarbeiten auch eher sekundär, solange die Analyse überzeugt.

5 Ein eigenes Korpus erstellen: Quick & Dirty

Im Folgenden gehen wir zunächst den “Quick&Dirty”-Weg, der sich allerdings nur für kleinere Datenmengen anbietet und relativ viel Fleißarbeit mit sich bringt. Hierbei übertragen wir die Daten manuell per Copy&Paste.

Da wir in unsere Analyse Artikel einbeziehen wollen, in denen es um das Thema Chatkontrolle geht, nutzen wir zunächst die Suchfunktion, um entsprechende Artikel zu finden.

NETZPOLITIK.ORG

Suchergebnisse für: „Chatkontrolle“

Chatkontrolle

Sortieren nach 493 Ergebnisse gefunden

- Relevanz
- Datum

Filter nach Jahr

- 2026 (21)
- 2025 (98)
- 2024 (96)
- 2023 (163)
- 2022 (96)

1 weitere anzeigen

Nur auf Verdacht

EU-Parlament stimmt gegen Massenüberwachung bei freiwilliger Chatkontrolle

Das EU-Parlament hat die Erlaubnis zur freiwilligen Chatkontrolle nochmals erneuert – doch möchte das Scannen auf Verdachtsfälle beschränken. Mit dieser Position geht das Parlament nun in Verhandlungen mit Rat und Kommission, die schon am Donnerstag beginnen.

von Markus Reuter 11. März 2026 3

Protest gegen die Chatkontrolle

So geht Demokratie

Der Etappensieg bei der Chatkontrolle ist das Verdienst einer quicklebendigen Zivilgesellschaft, die es geschafft hat, in klugen und

Figure 5.1: Screenshot der ersten Suchergebnisse für “Chatkontrolle” auf netzpolitik.org

Erwartungsgemäß finden wir eine recht stattliche Menge an Ergebnissen. Alle 493 Artikel manuell zu copy&pasten, wäre kaum möglich (automatisiert ist das hingegen kein Problem, dazu mehr im Advanced-Teil). Deshalb beschränken wir uns zunächst auf die ersten 20 Artikel. Je nach Fragestellung kann es aber auch sinnvoll sein, zunächst z.B. anhand der Überschriften nach den einschlägigsten Artikeln zu suchen und darauf aufbauend eine Auswahl zu treffen.

Um mit den Texten korpuslinguistisch weiterarbeiten zu können, ist es sinnvoll, sie zunächst offline zu speichern. Das geht beispielsweise, indem man sie in ein Textdokument kopiert. Ich empfehle, hier mit einem Texteditor wie Notepad++ oder BBEdit zu arbeiten und die Texte im Rohtextformat .txt zu speichern. Grundsätzlich wäre es zwar auch möglich, Texte z.B. in Word zu kopieren und dort damit weiterzuarbeiten, aber das Rohtextformat bringt für die weitere Verarbeitung eine Reihe von Vorteilen mit sich, während Word automatische